

CS542200 Parallel Programming

Homework 3: All-Pairs Short

student ID : 114062616 Name : 莊岱倫

1. Implementation

1.a Which algorithm do you choose in HW3-1?

- Blocked Floyd–Warshall 演算法
- Block-based round 更新 (pivot block \rightarrow pivot row/col \rightarrow remaining blocks)
- OpenMP 平行化

1.b How do you divide your data in HW3-2 and HW3-3?

HW3-2 (Single GPU – CUDA)

- **Padding 方法**

```
nPad = ((n + B - 1) / B) * B;
```

將原本的問題補齊至對齊block size, 所以整個matrix變成nPad x nPad
矩陣切成 rounds×rounds 個 blocks

```
rounds = nPad / B;
```

每個phase處理不同區域的block, 依序進行完成一個round

- **Block decomposition**

BlockDim = 32 X 32

phase1 : Pivot block

```
dim3 gridPhase1(1, 1);  
phase1<<<gridPhase1, blockDim>>>(Dist_d, nPad, B, r);
```

phase2 : Pivot row , Pivot col

```
dim3 gridPhase2(rounds - 1, 2);  
phase2<<<gridPhase2, blockDim>>>(Dist_d, nPad, B, r, rounds);
```

phase3 : 剩下來的那些block

```
dim3 gridPhase3(rounds, rounds); phase3<<<gridPhase3,  
blockDim>>>(Dist_d, nPad, B, r, rounds);
```

- Thread mapping

每 thread 處理 2×2 micro-tile (4 elements)

```
(off_i , off_j)  
(off_i , off_j + 1)  
(off_i + 1 , off_j)  
(off_i + 1 , off_j + 1)
```

設計原因

讀進來一次就可以在更新的地方用4次

使得thread存取資料時是連續的

HW3-3 (Multi-GPU)

Padding 和 thread mapping 的部分跟hw3-2相同這邊針對多GPU版本不同之處說明

- Divide between GPUs

整個 $nPad \times nPad$ 的距離矩陣先被切成 $B = 64$ 的區塊 (block tiles):

```
Block grid size = (rounds × rounds)  
where rounds = nPad / 64
```

每 GPU 要負責的 block rows

```
rounds = nPad / B;  
blocks_per_gpu = rounds / num_gpus;  
remainder      = rounds % num_gpus;
```

根據GPU tid分配

```
start_block = tid * blocks_per_gpu + (tid < remainder ? tid : remainder)
num_blocks  = blocks_per_gpu + (tid < remainder ? 1 : 0)
end_block   = start_block + num_blocks
```

每張 GPU 分到一段連續的 row blocks 因為 Floyd–Warshall 的運算是以 row 為核心(每次更新都是固定 i row 去讀 k row 和 k column), 所以把矩陣按 block-rows 切給不同 GPU, 可以讓每張 GPU 只負責自己那幾段 row 的更新, 不會互相衝突, 記憶體也只要存屬於自己的區塊;同時資料在每張 GPU 裡是連續的, 拷貝最有效率, Phase 1/2/3 的資料交換也最簡單

每張GPU拿到 num_blocks_of_GPU × 64 rows × nPad columns

- **Block decomposition**

Phase 1 (Pivot block)

```
phase1<<<1, blockDim>>>(Dist_local, nPad, r, start_block);
```

Phase 2: (Pivot row , Pivot column)

Phase2 col (兩張GPU都要執行)

```
phase2_Col<<<num_blocks, blockDim>>>
(Dist_local, PivotBlock, nPad, r, start_block, num_blocks);
```

tileA = Dist_local[i][r]

tileB = PivotBlock(來自 owner GPU)

讓所有 block rows 的 column r 都反映經過 pivot block (r,r) 更新後的最短路。

Phase2 row (只有owner GPU執行)

```
if (tid == owner_id) {
```

```

    phase2_Row<<<rounds, blockDim>>>(Dist_local, nPad, r,
start_block, rounds);
}

```

owner GPU 會 launch rounds 個 blocks

$j = 0..rounds-1$ 但會跳過 $j=r$ 去更新所有 (r, j) blocks

Phase3 (剩下的blocks)

```

dim3 gridPhase3(rounds, num_blocks);
phase3<<<gridPhase3, blockDim>>>
(Dist_local, RowBuffer, nPad, r, start_block);

```

Phase	哪些 Blocks	誰負責
Phase 1	(r, r) pivot block	只有 owner GPU
Phase 2 Row	(r, j)	owner GPU
Phase 2 Col	(i, r)	各 GPU 各處理自己的 block
Phase 3	(i, j) 其他區塊	各 GPU 各處理自己的 block

1.c What's your configuration in HW3-2 and HW3-3? And why?

HW3-2

- **Blocking factor $B = 64$**

因為 64×64 的 block factor 可以最大化的 reuse 資料, 並且也不會超過硬體限制, 同時也對應到我每個 thread 負責 4 elements 的實作策略

- **Threads per block = $32 \times 32 = 1024$**

透過 $32 \times 32 = 1024$ threads 正好可完整覆蓋一個 64×64 的 Floyd-Warshall block tile, 因為每個 thread 處理一個 2×2 micro tile

- **Grid**

Phase 1: 1×1

Phase 2: $(\text{rounds} - 1) \times 2$

Phase 3: $\text{rounds} \times \text{rounds}$

根據演算法邏輯每個 tile 分配一個 block

Phase 3 是因為 index mapping 所以多分配了一點 block 讓讀取時可以連續

HW3-3

- **Blocking factor $B = 64$**

因為 64×64 的 block factor 可以最大化的 reuse 資料, 並且也不會超過硬體限制, 同時也對應到我每個 thread 負責 4 elements 的實作策略

- **Threads per block = $32 \times 32 = 1024$**

透過 $32 \times 32 = 1024$ threads 正好可完整覆蓋一個 64×64 的 Floyd-Warshall block tile, 因為每個 thread 處理一個 2×2 micro tile

- **Grid**

Phase 1: 1×1


Phase 2 row: $(\text{rounds} - 1) \times 2$

Phase 2 col : $(\text{rounds} - 1) \times 2$

Phase 3: rounds \times rounds

這裡為了配合多GPU的通訊設計了兩個Phase2, 讓GPU之間的通訊可以只傳必須要的資料

1.d How do you implement the communication in HW3-3?



我採用 多 GPU + peer-to-peer (P2P) 直接傳輸 的方式來實作 Floyd-Warshall 的跨 GPU 溝通。整體流程完全對應 blocked FW 的三個 Phase, 分別傳遞:

1. pivot block ($B \times B$)
2. pivot row ($B \times n_{\text{Pad}}$)

Phase 1: Pivot block 由唯一 **owner GPU** 計算後「廣播」給所有 GPU

在 round r :

1. 計算出 哪個 **GPU** 擁有第 r 個 **block row** (owner)。
2. owner GPU 執行 Phase1 更新 pivot block (r, r)
3. 計算完成後, owner 把 pivot block ($B \times B$) 複製到 shared buffer:
4. owner GPU 對所有其他 GPU 做硬體 P2P 廣播:

Phase 2: Pivot Row 由 owner 更新後廣播給所有 GPU

Phase2 分成：

- **pivot column**: 所有 GPU 各自更新自己持有的 column block (i, r)
- **pivot row**: 只有 owner 擁有 row r, 因此 owner GPU 執行 Phase2_Row

Pivot row

owner GPU 會持有: Pivot block (r,r) Pivot row (r,*)

```
cudaMemcpy(RowBuffer, Dist_local + offset, B*nPad*sizeof(ushort));
```

把整個 pivot row ($B \times nPad$) 存到 RowBuffer。

因為其他 GPU 完全不保存 row r, 所以這個 buffer 是跨 GPU 唯一的 pivot row 資料來源。

然後再次Procast到其他GPU

```
cudaMemcpyPeerAsync(row_buf_ptrs[p], p, RowBuffer, tid,  
B*nPad*sizeof(ushort));
```

所以每張GPU就會有一份複製好的Pivot row Phase3時要使用

Phase 3: 所有 GPU 使用 PivotBlock + PivotRow 計算自己區域的 tile

在 Phase 3:

1. 所有 GPU 都已經擁有:
 - PivotBlock ($B \times B$)
 - PivotRow ($B \times nPad$)
2. 每個 GPU 使用自己 local 的 pivot column (從 Dist_local 載入)
3. 全 GPU 平行更新每個 (i, j) tile

完全沒有跨 GPU 互相依賴, 因此 Phase 3 不需要溝通。

同步機制

cudaDeviceSynchronize() – GPU kernel 層級同步

確保:

owner GPU 在 Phase1、Phase2 內的 kernel 已完成

資料寫入 PivotBlock、RowBuffer 已完成

(2) OpenMP barrier – 多 GPU thread 間同步

確保：

所有 GPU 等待 owner 廣播完成

所有 GPU 等待彼此收到 pivot 資料

1.e Briefly describe your implementations in diagrams / figures / sentences

1. 前置處理(Pre-processing)

(1) Padding 與 Dist 初始化

我先將矩陣 padding 到 $nPad = \lceil n / B \rceil * B$, 使矩陣可完整以 $B \times B$ block 處理。

啟動 kernel init_dist_kernel:

- 對角線初始化為 0
- 其他元素初始化為 INF (USHORT_MAX)
- 同時處理邊界 padding 區域

(2) Edge 更新

使用 update_edges_kernel 逐條將 input 中的 (u, v, w) 更新到 Dist。

2. Blocked Floyd-Warshall 核心

我採用 **Tile Size B = 64**, 並用 **32×32 threads** 來處理:

每個 thread 更新 2×2 微分塊, 使 $1024 \text{ threads} \times 4 \text{ elements} = 4096 \text{ elements}$ = 剛好一個 64×64 tile。

如此可以:

- 利用 **register** 暫存 4 個距離值, 降低 global 和 shared memory traffic
- 提升 **thread** 的工作量 (**thread-level locality**)
- 與 CUDA warp size (32) 完美配合

3. 三階段 Blocked FW (Phase 1 / Phase 2 / Phase 3)

Phase 1: 更新樞紐區塊 (Pivot Block, block (r,r))

運行流程

1. 取出第 r 回合中對角線上的那個 64×64 區塊。
2. 所有 threads 合作把這個 block 載到 shared memory。
3. 用 Floyd-Warshall 的 k -loop, 只更新這個 block 內部的距離。
4. 更新完後再寫回 Dist。

結果: 此 **pivot block** 會供後面兩階段使用。

Phase 2: 更新第 r 列與第 r 行的其他區塊

概念: **Pivot block** 幫助整條 row & column 變更短

1. 針對第 r row 和第 r column 的其他 blocks 各跑一次 (不包含 pivot block)。
2. 同時載入 (到 shared memory):
 - 該 block 自己的資料
 - 樞紐 block 的資料
3. 用 pivot block 當「中繼點」, 更新 row/column 上的距離。
4. 寫回更新後的內容。

結果: 整條第 r row 與第 r column 已經反映經過 **pivot k** 的最短路。

Phase 3: 更新其他不在第 r row / r column 的所有區塊

概念: 用 **pivot row + pivot column** 影響全地圖

1. 對所有「不在 row r 、也不在 col r 」的 blocks 分別進行更新。
2. 每個 block 載入:
 - pivot row slice
 - pivot column slice
 - block 本身的資料
3. 用 $(i \rightarrow r \rightarrow j)$ 路徑測試是否能縮短 block 內的距離。
4. 更新後寫回。

4. Output(後處理)

我使用 mmap + pinned memory(cudaHostRegister)產生輸出檔案：

1. dist_to_out_kernel 把 Dist_d 轉成 int
2. cudaMemcpyAsync + stream 同步移到 host
3. 直接寫進 memory-mapped output file(完全避免中間拷貝)

2. Profiling Results (HW3-2)

Profile instruction

```
srunk nvrprof --kernels "phase3*" --metrics \
achieved_occupancy,sm_efficiency,shared_load_throughput,shared_store_throughput,\
gld_throughput,gst_throughput \
./hw3-2 ./testcases/c21.1 ./out
```

Invocations	Metric Name	Metric Description	Min	Max	Avg
Device "NVIDIA GeForce GTX 1080 (0)"					
Kernel: phase3(unsigned short*, int, int, int, int)					
9	achieved_occupancy	Achieved Occupancy	0.816950	0.874147	0.836668
9	sm_efficiency	Multiprocessor Activity	70.12%	71.40%	70.71%
9	gld_throughput	Global Load Throughput	93.7566B/s	95.2706B/s	94.5146B/s
9	gst_throughput	Global Store Throughput	46.8786B/s	47.6356B/s	47.2576B/s
9	shared_load_throughput	Shared Memory Load Throughput	2250.16B/s	2286.56B/s	2268.36B/s
9	shared_store_throughput	Shared Memory Store Throughput	93.7566B/s	95.2706B/s	94.5146B/s

occupancy	83%
sm efficiency	70%
shared memory load throughput	2268.3 GB/s
shared memory store throughput	94.514 GB/s
global load throughput	94.514 GB/s
global store throughput	47.257 GB/s

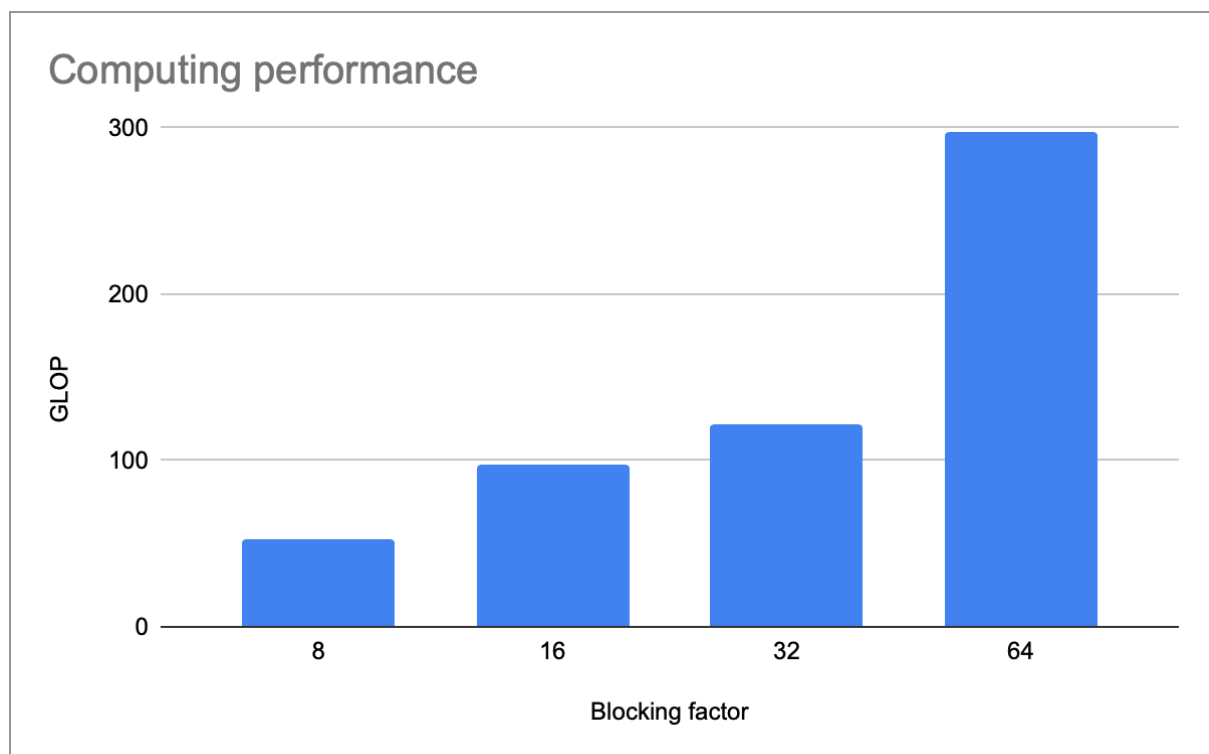
83% 的 occupancy 與 70% 的 SM efficiency 代表 warp 排程與計算管線利用良好，而 global load/store throughput 僅約 30% 的 GTX1080 理論頻寬、同時 shared memory load throughput 高達 2.2 TB/s，顯示 kernel 已成功將運算重心從 DRAM 移入 shared memory，再配合 register 累積更新，因此效能主要受限於 shared memory access latency 與指令管線，而非記憶體頻寬

3. Experiment & Analysis (NVIDIA GPU)

3.a System Spec

我是Apollo gpu cluster 所以不特別放spec

3.b Blocking Factor (HW3-2)



GLOPS

根據圖中的結果，當 Blocking Factor 從 $8 \rightarrow 16 \rightarrow 32 \rightarrow 64$ 增加時，Computing Performance (GLOP) 呈現明顯的單調遞增，最終在 64 達到最高的 300 GLOP。


當 block size 越大，表示：

- 同一個 tile 中包含更多的 row / col pair
- 同一個 pivot row/col 可以在 shared memory 被重複使用更多次
- 每載入一次 pivot block 或 tile 可產生更多 FLOPs

所以計算密度 (arithmetic intensity) 隨 block size 增大而提升。


在 block = 64 時：

每次載入的 64×64 tile 帶來最大的 FLOP reuse, 因此 GLOP 值最高。



Shared memory throughput

blocking factor = 8 or 16 都會讓shared memory的bandwidth使用不足, 只有在32 與 64 都能吃到 **shared memory** 較高的bandwidth但根據GLOP的觀察64才是更高頻寬且高 **occupancy**的選擇, 在這張圖中64也是表現最好的blocking factor



Global Memory Bandwidth

因為有很大部分的資料搬移到shared memory重複使用，所以global bandwidth高不代表比較好，要在一個合理的範圍thread一開始搬移至shared memory的bandwidth足夠即可，以圖片來看 8 和16太小kernel 啟動次數太多，反而是64時因為需要的資料都一次搬進去shared memory不用多次班取重複資料，所以bandwidth最低

3.c Optimization (HW3-2)

優化的過程為每個改善功能的疊加，依照profile看到的方向做優化

GPU baseline (Time 19.51)

	metric	avg	total
1	shared_ld_bank_conflict	0.000000	0.000000
2	shared_st_bank_conflict	0.000000	0.000000
4	achieved_occupancy	0.947387	0.943184
5	ipc	1.758657	1.467027
6	gld_throughput	737.412409	719.487745
7	gst_throughput	57.513096	27.858591
8	l2_read_throughput	737.428298	719.535057
9	l2_write_throughput	57.516171	27.861855
10	shared_efficiency	0.000000	0.000000
11	warp_execution_efficiency	100.000000	96.473516
12	issue_slot_utilization	39.625053	32.055247
13	stall_inst_fetch	3.657524	2.744034
14	stall_exec_dependency	11.086647	10.500854
15	stall_memory_dependency	81.676187	80.471178
16	stall_constant_memory_dependency	1.034380	0.346409
17	stall_texture	0.000024	0.000003
18	stall_sync	0.000000	0.000000
19	stall_pipe_busy	0.417765	0.189777
20	stall_other	7.722840	4.179223
21	gld_efficiency	75.982997	74.929017
22	gst_efficiency	32.082507	20.348786

因為完全使用global mem操作，所以global mem throughput非常，kernel 現在主要被「記憶體存取延遲」嚴重卡住，算力沒有吃滿，優化方向應該集中在降低 memory dependency、減少 global store、提升資料重用

Padding (Time 19.07)

	metric	avg	total
1	shared_ld_bank_conflict	0.000000	0.000000
2	shared_st_bank_conflict	0.000000	0.000000
4	achieved_occupancy	0.957986	0.951264
5	ipc	2.005655	1.810458
6	gld_throughput	749.271133	740.738237
7	gst_throughput	63.751667	30.774228
8	l2_read_throughput	749.289689	740.791005
9	l2_write_throughput	63.755385	30.778011
10	shared_efficiency	0.000000	0.000000
11	warp_execution_efficiency	100.000000	99.099340
12	issue_slot_utilization	44.138878	39.304763
13	stall_inst_fetch	7.712725	3.960537
14	stall_exec_dependency	12.921456	12.688551
15	stall_memory_dependency	76.626372	75.590427
16	stall_constant_memory_dependency	0.507879	0.378951
17	stall_texture	0.000031	0.000006
18	stall_sync	0.000000	0.000000
19	stall_pipe_busy	0.336278	0.243856
20	stall_other	8.570561	5.363145
21	gld_efficiency	89.575181	89.391811
22	gst_efficiency	34.998890	21.228220

Padding 明確提升了記憶體存取效率, 使指令吞吐與 SM 利用度上升, 因為他可以省去一些邊界判斷的檢查

Register cacheing (Time = 10.8)

	metric	avg	total
1	shared_ld_bank_conflict	0.000000	0.000000
2	shared_st_bank_conflict	0.000000	0.000000
4	achieved_occupancy	0.837795	0.829453
5	ipc	2.421754	2.339517
6	gld_throughput	914.764590	885.182086
7	gst_throughput	22.311331	21.589807
8	l2_read_throughput	914.803191	885.377149
9	l2_write_throughput	22.319172	21.597394
10	shared_efficiency	0.000000	0.000000
11	warp_execution_efficiency	100.000000	100.000000
12	issue_slot_utilization	50.367436	48.660615
13	stall_inst_fetch	4.906819	2.788649
14	stall_exec_dependency	34.497757	33.866285
15	stall_memory_dependency	9.886983	9.521259
16	stall_constant_memory_dependency	1.062738	0.837803
17	stall_texture	1.217584	1.009083
18	stall_sync	0.000000	0.000000
19	stall_pipe_busy	1.759431	1.639869
20	stall_other	47.702475	46.638134
21	gld_efficiency	82.926829	82.926829
22	gst_efficiency	100.000000	100.000000

IPC

指標	改善前	改善後
IPC	~2.00	2.42

Pipeline被塞得更滿，因為global mem的存取相依被減緩了，可以花更多時間在處理指令

Memory ThroughputMemory Stalls

指標	改善前	改善後
gld_throughput	~749 GB/s	914 GB/s
l2_read_throughput	~749 GB/s	914 GB/s

因為memory store的stall大幅下降，因為不用重複一直讀同一個D[i][j]，把整體資料流順暢度都提升了

Memory Stalls

Stall Type	改善前	改善後	意義
stall_memory_dependency	~76%	~9.8%	核心瓶頸被解鎖
stall_exec_dependency	~12%	~34%	代表瓶頸轉向 compute chain , 而非 memory
stall_other	~8%	~47%	代表 pipeline 正在忙著處理而不是等待

因為memory store的stall大幅下降, 因為不用重複一直讀同一個D[i][j], 把整體資料流順暢度都提升了

Issue Slot Utilization

指標	前	後
Issue Slot Utilization	~44%	50%

原本

```
for (int k = 0; k < B; k++) {
    int oldVal = Dist[i * nPad + j];
    int via = Dist[i * nPad + k] + Dist[k * nPad + j];
    Dist[i * nPad + j] = min(oldVal, via);
}
```

改善後

```
int dij = Dist[i * nPad + j];
for (int k = 0; k < B; k++) {
    int via = Dist[i * nPad + k] + Dist[k * nPad + j];
    dij = min(dij, via);
}
Dist[i * nPad + j] = dij;
```

1 thread process 4 elements (Time = 8.59)

	metric	avg	total
1	shared_ld_bank_conflict	0.000000	0.000000
2	shared_st_bank_conflict	0.000000	0.000000
4	achieved_occupancy	0.907009	0.892508
5	ipc	2.241561	2.094174
6	gld_throughput	764.363607	725.662673
7	gst_throughput	58.797201	55.820206
8	l2_read_throughput	764.414469	725.771319
9	l2_write_throughput	58.807532	55.830014
10	shared_efficiency	0.000000	0.000000
11	warp_execution_efficiency	100.000000	99.912886
12	issue_slot_utilization	47.938021	44.767135
13	stall_inst_fetch	11.292953	5.837986
14	stall_exec_dependency	12.484531	10.915533
15	stall_memory_dependency	75.227984	71.149725
16	stall_constant_memory_dependency	1.378557	0.954595
17	stall_texture	4.766012	1.876801
18	stall_sync	0.000000	0.000000
19	stall_pipe_busy	1.429276	1.276730
20	stall_other	18.058510	4.748315
21	gld_efficiency	38.461538	38.461538
22	gst_efficiency	50.000000	50.000000

Global Load Throughput

Metric	改善前	改善後
gld_throughput	~915 GB/s	~764 GB/s

我不在需要這麼多次load因為我重複使用了周圍的4 elements的資料

Achieved Occupancy

Metric	改善前	改善後
achieved_occupancy	0.8378	0.9070

因為每個 warp 一次處理更多資料，計算佔比提高、記憶體 I/O 等待時間降低，因此 warp 不需要頻繁切換，讓更多 warp 能持續處於可執行狀態，進而提升 Occupancy、提高 SM 資源利用率，讓 GPU 整體更忙、更有效率。

Shared memory (Time = 6.48)

	metric	avg	total
1	shared_ld_bank_conflict	0.000000	0.000000
2	shared_st_bank_conflict	18496.000000	332928.000000
4	achieved_occupancy	0.855130	0.843596
5	ipc	2.733383	2.588445
6	gld_throughput	307.076223	253.186303
7	gst_throughput	87.736064	72.338944
8	l2_read_throughput	307.152120	253.512224
9	l2_write_throughput	87.751480	72.351655
10	shared_efficiency	39.285714	39.285714
11	warp_execution_efficiency	100.000000	99.911024
12	issue_slot_utilization	58.846432	55.717714
13	stall_inst_fetch	10.166955	5.323307
14	stall_exec_dependency	17.877136	16.969814
15	stall_memory_dependency	37.855935	27.369052
16	stall_constant_memory_dependency	1.489854	1.185965
17	stall_texture	0.127647	0.094031
18	stall_sync	4.915293	3.797776
19	stall_pipe_busy	4.500625	4.163025
20	stall_other	38.840516	36.188478
21	gld_efficiency	42.857143	42.857143
22	gst_efficiency	50.000000	50.000000

將Pivot row Pivot col存入shared mem因為這部分會一直重複用到所以搬到存取速度快的shared mem

Global Memory

指標	改善前	改善後（使用 shared memory）
gld_throughput	~915 GB/s	~307 GB/s
gst_throughput	~22 GB/s	~87.7 GB/s
l2_read_throughput	~915 GB/s	~307 GB/s
gld_efficiency	82.9%	42.9%

明顯看到IO很大一部分因為shared mem加入而被節省，運行過程更少去觸碰到global mem load所以throught put 大幅下降

IPC

指標	改善前	改善後	改善重點
IPC	~2.24	~2.73	ALU 更忙、pipeline 更飽

IPC 上升代表 memory latency 被有效隱藏，整題運行比重更靠向compute而不是IO

Memory Stall

指標	改善前	改善後	改善重點
stall_memory_dependency	~75%	~38%	Memory 等待時間明顯下降
stall_exec_dependency	~12%	~18%	變成 compute dependency 為主
stall_pipe_busy	~1.7%	~4.5%	Pipeline 使用率提高

pipeline因為IO在hared mem的部分較快所以更少stall發生，整體pipeline運行更加順暢

Issue Slot Utilization

指標	改善前	改善後	改善重點
issue_slot_utilization	~47.9%	~58.8%	指令發射更頻繁、空洞更少

ushrot + no bankconflict (Time = 2.12)

	metric	avg	total
1	shared_ld_bank_conflict	0.000000	0.000000
2	shared_st_bank_conflict	0.000000	0.000000
4	achieved_occupancy	0.854881	0.832872
5	ipc	2.443041	2.402182
6	gld_throughput	108.772834	108.475473
7	gst_throughput	54.386417	54.237737
8	l2_read_throughput	110.169848	108.911711
9	l2_write_throughput	54.407993	54.259254
10	shared_efficiency	70.000000	70.000000
11	warp_execution_efficiency	100.000000	100.000000
12	issue_slot_utilization	50.402767	49.560412
13	stall_inst_fetch	2.810940	2.165510
14	stall_exec_dependency	35.785947	34.887681
15	stall_memory_dependency	1.014400	0.860602
16	stall_constant_memory_dependency	2.836438	2.296423
17	stall_texture	0.171754	0.135151
18	stall_sync	15.460733	12.692194
19	stall_pipe_busy	1.598041	1.195300
20	stall_other	44.042076	42.068448
21	gld_efficiency	75.000000	75.000000
22	gst_efficiency	50.000000	50.000000
23	sm_efficiency	70.693518	69.905423
24	shared_load_throughput	2610.548006	2603.411356
25	shared_store_throughput	108.772834	108.475473

Bank conflict

此版本把原本的bank conflict全部消除，進一步提升IO效率

Global memory

指標	改進前	最終版本
gld_throughput	~307-900+ GB/s	108 GB/s
l2_read_throughput	~300-900+ GB/s	110 GB/s
gld_efficiency	~42%	75%
gst_throughput	~87 GB/s	54 GB/s

因為ushort讓每一筆資料大小縮短, 所以整體IO需要傳輸的量也變小造成IO速度變快

Shared Memory

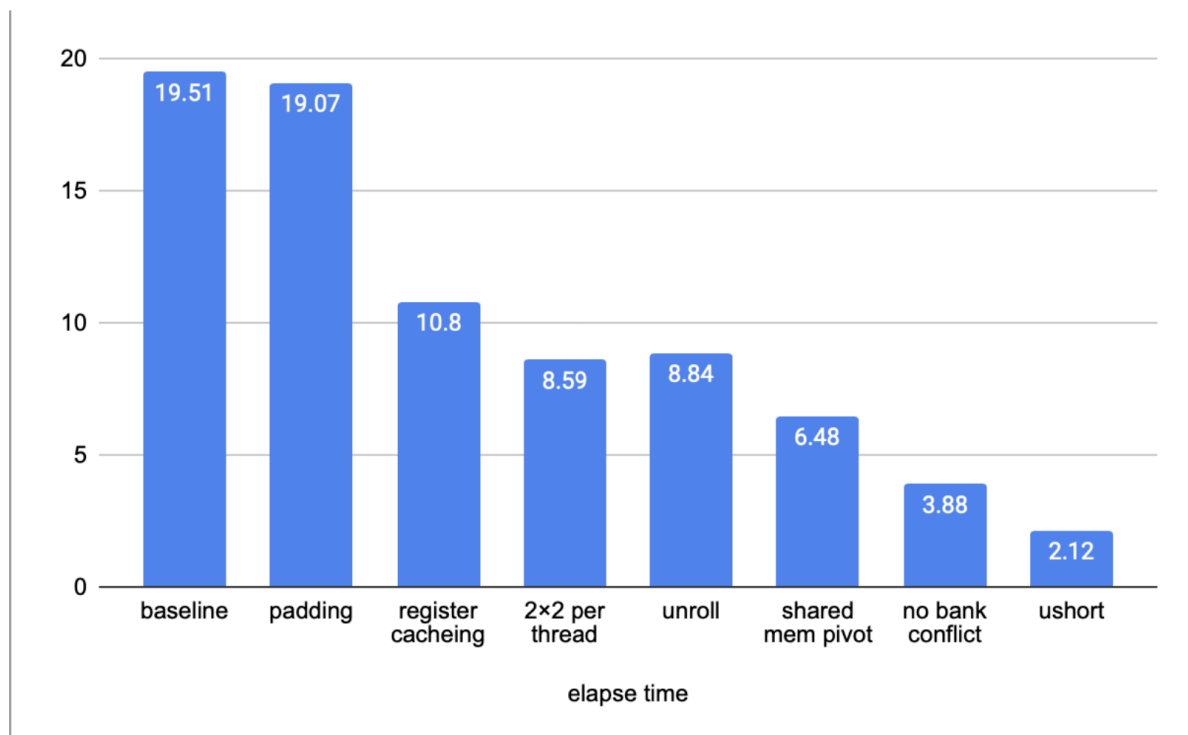
指標	改進前	最終版本
shared_efficiency	~39%	70%

Shared memory的使用率大幅提升是因為bank conflict被完全解除

Stall

指標	改進前	最終版本
stall_memory_dependency	~38-75%	1%
stall_exec_dependency	~18%	36%

幾乎沒有因為memory而暫停, 整體pipeline運行進一步提升



3.d Weak Scalability (HW3-3)

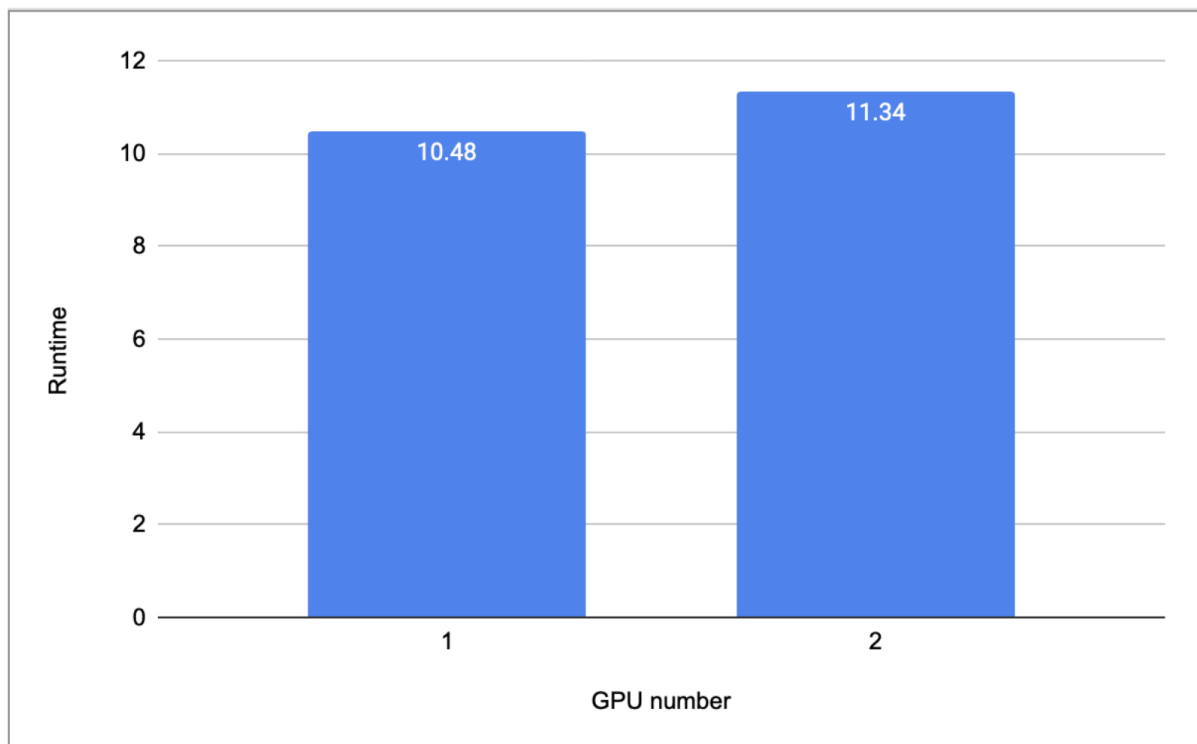
因為FW的運算複雜度大概是 $2^{1/3}$ 所以選擇

testcase(23) n=22000 , testcase(28) n =27000

盡量讓計算量是兩倍的提升

Profile instrustion

```
srunc -p nvidia -N1 -n1 --gres=cpu:1 nvprof --print-gpu-summary  
./hw3-3 ./testcases/p23k1 ./out  
srunc -p nvidia -N1 -n1 --gres=cpu:2 nvprof --print-gpu-summary  
./hw3-3 ./testcases/p28k1 ./out
```



只有因為通訊overhead有些微的時間增加, scalability十分不錯因為不會有大量的資料在gpu之間傳輸, 只傳當下任務的所必需使用的資料區段, 所以通訊埠沒有造成明顯的效能損失

3.e Time Distribution (HW3-2)

Profile instrustion

```
srun nvprof --print-gpu-summary ./hw3-2 ./testcases/p26k1 ./out
```

```
pp25s121@apollo-login:~/Parallel-Computing/hw3$ srun nvprof --print-gpu-summary ./hw3-2 ./testcases/p26k1 ./out
srun: No GPU specified, defaulting to allocating 1 GPU
==384771== NVPROF is profiling process 384771, command: ./hw3-2 ./testcases/p26k1 ./out
==384771== Profiling application: ./hw3-2 ./testcases/p26k1 ./out
==384771== Profiling result:
   Type  Time(%)   Time    Calls    Avg     Min     Max   Name
GPU activities:  95.58%  14.7958s   405  36.533ms  35.521ms  37.707ms phase3(unsigned short*, int, int, int, int)
                  2.95%   457.11ms   405   1.1287ms  1.0888ms  1.2417ms phase2(unsigned short*, int, int, int, int)
                  0.73%   112.23ms    1   112.23ms  112.23ms  112.23ms [CUDA memcpy HtoD]
                  0.67%   103.77ms    1   103.77ms  103.77ms  103.77ms [CUDA memcpy DtoH]
                  0.07%   10.641ms   405   26.273us  25.504us  30.433us phase1(unsigned short*, int, int, int)

==384771== NVTX result:
==384771== Thread "<unnamed>" (id = 1907331072)
==384771== Domain "<unnamed>"
==384771== Range "Computation"
   Type  Time(%)   Time    Calls    Avg     Min     Max   Name
Range: 100.00%  15.4818s    1  15.4818s  15.4818s  15.4818s Computation
GPU activities:  95.58%  14.7958s   405  36.533ms  35.521ms  37.707ms phase3(unsigned short*, int, int, int, int)
                  2.95%   457.11ms   405   1.1287ms  1.0888ms  1.2417ms phase2(unsigned short*, int, int, int, int)
                  0.73%   112.23ms    1   112.23ms  112.23ms  112.23ms [CUDA memcpy HtoD]
                  0.67%   103.77ms    1   103.77ms  103.77ms  103.77ms [CUDA memcpy DtoH]
                  0.07%   10.641ms   405   26.273us  25.504us  30.433us phase1(unsigned short*, int, int, int)

==384771== Range "Input"
   Type  Time(%)   Time    Calls    Avg     Min     Max   Name
Range: 100.00%  1.14446s    1   1.14446s  1.14446s  1.14446s Input
No kernels were profiled in this range.

==384771== Range "Output"
   Type  Time(%)   Time    Calls    Avg     Min     Max   Name
Range: 100.00%  3.86223s    1   3.86223s  3.86223s  3.86223s Output
No kernels were profiled in this range.
```

因為是單節點單卡所以並沒有communication的部分

項目	秒數
Computing (kernel 1 + 2 + 3)	15.4818 s
Memory Copy H2D	112.23 ms
Memory Copy D2H	103.77 ms
Input	1.14446 s
Output	3.86223 s

整體程式執行狀態已經變成compute bound, 尤其是phase3佔了很大一部分的GPU time, 這也證明前幾個版本對memory的優化有奏效

AMD GPU Porting and Analysis

Profile instruction

```
srun -p amd -N1 -n1 \  
rocprofv2 --basenames -i ./profile-amd/metrics.txt -o  
profile-amd-p2  
0k1 -d ./profile-amd/profile-result \  
./hw3-2-amd ./testcases-amd/p20k1 ./p20k1.out
```

a. Implementation

cuda 和 Hip其實功能非常相近, 只有一些function名稱不同

CUDA	HIP
cudaMalloc	hipMalloc
cudaFree	hipFree
cudaMemcpy	hipMemcpy
cudaMemcpyHostToDevice	hipMemcpyHostToDevice
cudaMemcpyDeviceToHost	hipMemcpyDeviceToHost
cudaDeviceSynchronize	hipDeviceSynchronize
cudaMallocHost	hipHostMalloc
cudaFreeHost	hipHostFree

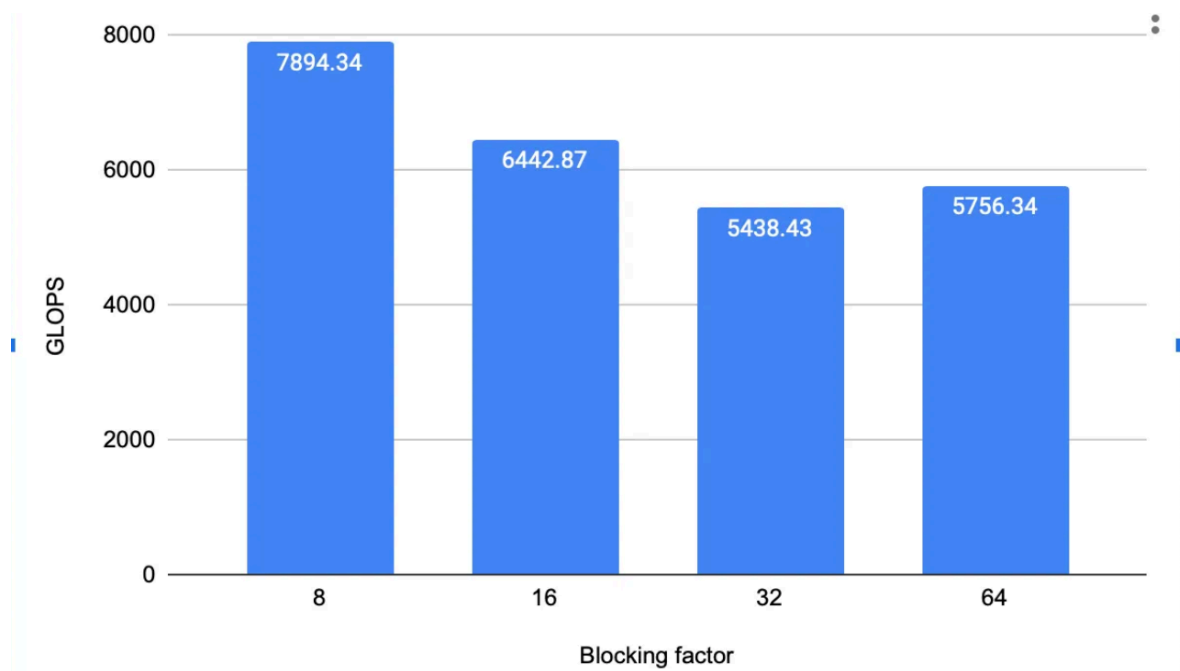
因為kernel內部結構都不變, 基本上就是把function名稱改完就能正常運行

b. Experiment & Analyze

Blocking Factor on AMD (MI210)

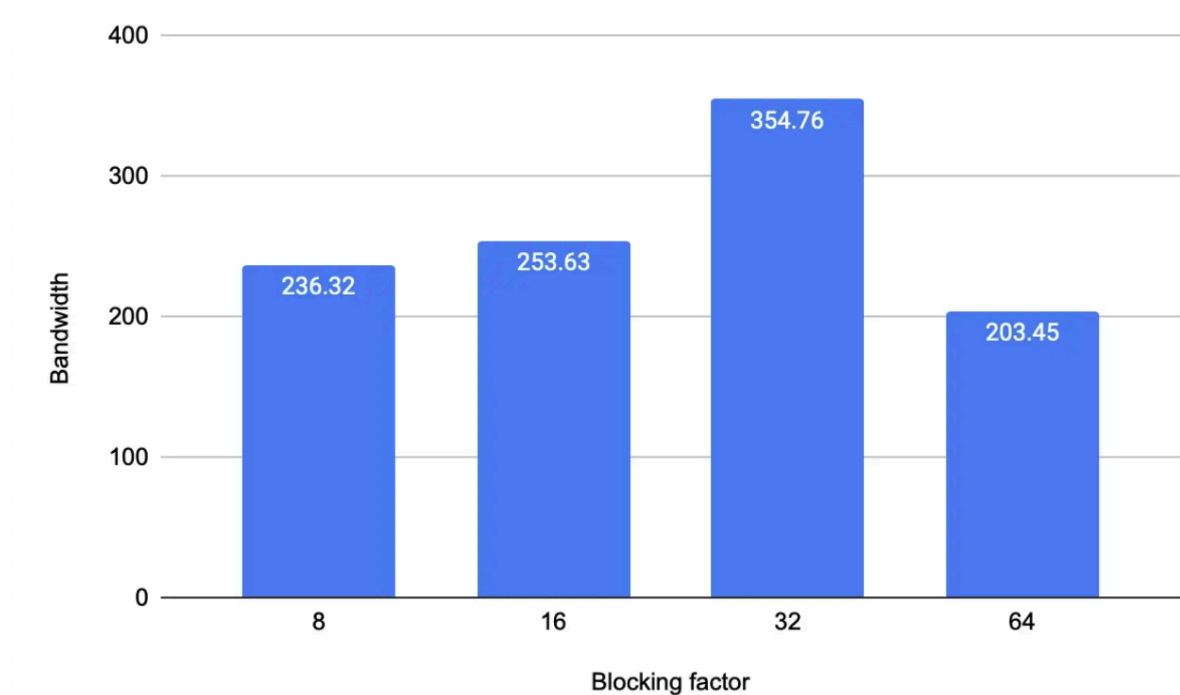
B = 32 最佳

GLOP




隨著 B 從 8→16→32 持續上升, 在 B=32 時達到最高;這代表在 MI210 上 32×32 的 tile 已經能提供足夠的資料重複使用與並行度, 讓大量整數 min/add 運算把 ALU 填滿, 而 B=64 雖然 tile 更大, 但因為每個 block 需要更多 LDS 空間與暫存器, 降低了每個 CU 可同時常駐的 wave/block 數, 導致整體 GOPS 反而掉下來, 說明此時受到 occupancy 限制。

Global memory performance



B=8/16 由於 tile 太小，對 HBM2e 的存取次數多、重用度差，雖然 MI210 有高達 1.6 TB/s 的理論頻寬，實際量測卻無法有效吃滿；B=32 時 global BW 提升到接近曲線峰值，同時因為大部分中間資料都能在 LDS 內重用，單位運算所需的 global traffic 也最低，形成「GOPS 高 + global BW 利用率高但不浪費」的最佳平衡；B=64 雖然 global BW 不會明顯變差，但前面提到的 occupancy 與 LDS 壓力讓整體效能(GOPS)已經開始下滑。

Shared memory performance



B=8 與 16 的 shared BW 只有約 1.8k 與 2.3k(任意單位)，而 B=32 直接跳到約 4953，接近前兩者的兩倍，B=64 則稍微下降到約 4353。這表示在 MI210 每個 CU 只有 64 KB LDS 的硬體條件下，B=32 剛好讓 tile 足夠大，可以在 LDS 裡做高效率的資料重用與平行載入，最大化 LDS 管線吞吐；B=64 時 LDS 使用量過大、active blocks 變少，甚至更容易產生 bank conflict，導致 shared BW 雖然仍高，但已低於 B=32 的峰值。

Compare NVIDIA vs AMD

概念	NVIDIA (GTX 1080, CUDA)	AMD (MI210, ROCm/HIP)
thread	thread	work-item / thread
block	block / CTA	work-group
warp 單位	warp = 32 threads	wavefront = 64 threads
SM / CU	SM (Streaming Multiprocessor)	CU (Compute Unit)

整體再將code移植過來的過程中可以看到profile結果都顯示，只是API名稱是無法取得好的效能，因為這兩張卡不只我上述提到warp中threads數不同，頻寬以及各階層記憶體大小都不同，我直接拿針對GTX 1080有優勢的code來改，其實沒辦法完全發揮amd卡，但由於時間的關係也只有做warp threads mapping部分的優化，課程結束後會再花更多時間把amd卡的效能也tune到完全發揮出來

AMD-specific Optimization

Wavefront 64–Aligned Thread Mapping


在 AMD GPU 上，一個 Wavefront 由 **64 個 threads** 組成。因此，我將原本採用 NVIDIA warp 對齊的 blockDim(32, 32)，重新設計為 blockDim(64, 16)，讓 **X 維度** 正好對齊 **64 threads**。

改善：

- **Global memory access 完整 coalescing**
64 個 threads 讀寫連續位址使記憶體頻寬利用率提高
- **Shared memory bank conflict 大幅降低**
不同 threads 打到不同 bank，符合 AMD LDS 結構
- **Wavefront 不會出現閒置或浪費**
不像原本 warp=32 的 mapping 會導致硬體使用不均

改善適合AMD Gpu maaping的寫法後，occupancy就明顯有上升，證明原本的寫法會讓一部分的threads是空轉的狀態

AMD Weak Scaling



圖表顯示我的weak scalability不太好，因為我在改寫amd版本的code時將資料整行整列的都搬運到兩張GPU上，所以有很多多餘的資料傳遞

並且我沒有針對amd gpu有的硬體做到完全的優化，所以有很多運算資源是閒置的，導致資料傳輸pipeline可能受到延遲的影響間接影響道gpu之間的通訊